

# Sujet d'examen

## Cibler une campagne de marketing bancaire de manière responsable

### Contexte

---

Les banques de détail mènent régulièrement des campagnes de démarchage téléphonique pour proposer à leurs clients des produits d'épargne, tels que les dépôts à terme. Ces campagnes ont un coût élevé (temps des conseillers, plateformes d'appels) et, mal ciblées, elles saturent les clients d'appels non pertinents et dégradent la relation commerciale. Identifier en amont les clients les plus susceptibles de souscrire permet de concentrer l'effort sur les bons profils, de réduire le nombre d'appels inutiles et d'améliorer l'expérience client.

Grâce à l'IA, il est possible d'estimer la probabilité qu'un client souscrive à partir de son profil et de l'historique des contacts. Mais démarcher sur la base de données personnelles (âge, profession, situation familiale, niveau d'éducation) soulève des questions d'équité, de conformité au RGPD et de pratiques commerciales acceptables. Une solution performante mais discriminante ou opaque n'est pas déployable en l'état.

Pour illustrer ce cas d'usage, un jeu de données public issu d'une banque portugaise vous est fourni (UCI Bank Marketing). Il contient, pour chaque client contacté, des caractéristiques socio-démographiques, l'historique des contacts, le contexte socio-économique et la variable cible : le client a-t-il souscrit (oui/non). L'enjeu consiste à exploiter ces données pour prédire la souscription, tout en respectant les contraintes réglementaires et éthiques liées à l'usage de données personnelles.

### Sujet du projet : construire, évaluer et exposer un modèle prédictif de souscription

---

Dans ce projet, vous incarnez un-e ingénieur-e IA pour concevoir une solution prédictive estimant si un client souscrira à un produit d'épargne. L'objectif est de produire une solution IA robuste, explicable, conforme aux bonnes pratiques d'ingénierie des données et aux exigences éthiques et réglementaires.

Vous disposez du fichier **bank-additional-full.csv** (41 188 observations, 20 variables explicatives + 1 variable cible). Un dictionnaire complet des variables figure en fin de sujet.

**Jeu de données (source) :** UCI Machine Learning Repository Bank Marketing

#### Objectif principal

L'objectif est de **prédire si un client souscrira (oui/non)** à partir des informations disponibles avant l'issue de la campagne. Il s'agit d'une tâche de **classification binaire** (cible **y**).

Vous devrez **entraîner plusieurs modèles** (par exemple une régression logistique comme référence, puis un arbre de décision ou une forêt aléatoire), comparer leurs performances avec des **métriques appropriées**, et analyser la robustesse de vos résultats à l'aide de la **validation croisée**.

**À surveiller** — la classe « oui » est nettement minoritaire (environ 11 % des observations). Un modèle qui prédit toujours « non » obtiendra une exactitude élevée sans aucune utilité. Choisissez des métriques qui rendent compte de la classe positive (précision, rappel, F1-score, ROC-AUC, matrice de confusion) et documentez votre choix.

## Préparation des données

Avant toute modélisation, réalisez une exploration puis une préparation raisonnée du jeu de données, tout en vous assurant de sa bonne qualité avant toute manipulation .

## Analyse comparée des scénarios

Un point essentiel de votre mission consiste à comparer les performances obtenues selon différents jeux de variables. Cette analyse vous permettra d'objectiver l'impact des variables discutables — celles qui posent un problème de fuite d'information (leakage) ou un problème éthique.

1. **Scénario 1 — Toutes les variables disponibles.** Vous utilisez l'ensemble des colonnes, y compris la durée du dernier appel (duration). Ce scénario sert de performance de référence.
2. **Scénario 2 — Sans la variable duration.** Vous retirez la durée du dernier appel et comparez à la référence.

**À interroger** — à quel moment la durée d'un appel est-elle réellement connue ? Si elle n'est disponible qu'une fois l'appel terminé, peut-on légitimement l'utiliser pour décider, en amont, qui appeler ? Commentez l'écart de performance observé entre les scénarios 1 et 2.

3. **Scénario 3 — Sans variables sensibles.** Vous retirez en plus les variables que vous jugez éthiquement discutables pour un ciblage commercial (par exemple l'âge, la profession, la situation familiale, le niveau d'éducation), en justifiant chaque retrait.
4. **Scénario 4 (optionnel) — Modèle minimal.** Sans variables sensibles et sans historique de campagne, pour tester la faisabilité d'un modèle reposant uniquement sur un socle de variables réduit.

Votre objectif est de **documenter et commenter l'impact de chaque scénario** sur les performances des modèles, puis d'**argumenter le choix final du modèle et des variables** à retenir dans un contexte réel, en tenant compte des enjeux éthiques, légaux et de robustesse.

## Phase d'industrialisation — exposer la solution IA

---

Une fois le modèle validé, préparez son passage en production, son suivi et son évolution dans le temps.

### 1. Exposer le modèle via une API

Exposez le modèle sous forme de service afin qu'un utilisateur non technique (conseiller, responsable de campagne) puisse l'interroger.

- **API de prédiction.** Développez une API (par exemple avec FastAPI) exposant au minimum : une route de prédiction (POST) prenant en entrée les caractéristiques d'un client et renvoyant la probabilité de souscription, et une route de santé (health) permettant de vérifier que le service fonctionne.
- **Robustesse.** Prévoyez la validation des données entrantes, une gestion propre des erreurs et la journalisation de chaque requête (entrées, sortie, horodatage).

### 2. Concevoir l'architecture cible

Proposez une architecture cible pour déployer la solution en conditions réelles, sous la forme d'un schéma simple des composants.

- **Contraintes de performance et d'infrastructure.** Le modèle mobilise des variables tabulaires (catégorielles encodées et numériques). Vous évaluez le rapport performance / coût computationnel d'inférence et discuterez du choix de l'infrastructure d'hébergement : déploiement sur site (on-premise) pour des raisons de confidentialité des données ou sur un Cloud souverain. Vous estimerez la latence acceptable pour un conseiller qui interroge le service avant de contacter un client, et dimensionnerez les ressources (CPU / RAM).
- **Acteurs à consulter.** Identifiez les acteurs à mobiliser pour valider cette architecture (SI, conformité / DPO, équipe métier).

### 3. Mesurer la performance et les impacts en production

Les métriques d'entraînement ne suffisent plus une fois le modèle déployé. Proposez un suivi de la solution en production.

- Métriques techniques : temps de réponse, taux d'erreur, disponibilité.
- Métriques métier : écart entre le taux de souscription réel et la probabilité prédite, évolution du profil des clients contactés (dérive des données).
- Proposez un moyen simple de rendre ces indicateurs visibles à un utilisateur non technique (tableau de bord).

### 4. Faire évoluer la solution en continu

Mettez en place un dispositif d'évaluation continue de la solution, intégrée à votre chaîne de développement, au-delà de sa mise en production initiale.

- **Ré-entraînement** Implémentez les critères déclenchant un réentraînement du modèle (dégradation d'une métrique de performance par exemple). Expliquez en quoi le suivi d'une ou de plusieurs métriques permet d'observer l'évolution des performances de la solution.
- **Boucle de rétroaction.** Mettez en place un mécanisme permettant d'intégrer les retours terrain dans le cycle d'amélioration via une boucle de rétroaction (feedback loop, exemple : les remontées des conseillers)
- **Automatisation CI/CD.** Automatisez l'évaluation du modèle ainsi que son réentraînement et son déploiement au sein d'une chaîne CI/CD (par exemple avec Github Actions) en fiabilisant les tests.
- **Maîtrise des risques.** Définissez une stratégie limitant les risques d'une mise à jour en production (par exemple : comparaison champion/challenger) et imaginez une périodicité à laquelle la pertinence des indicateurs suivis sera réinterrogée.

**Option avancée (bonus).** Pour valoriser votre copie, sans que cela soit exigé pour la validation : conteneurisation avec Docker ; suivi des expériences avec MLflow (versions du modèle, hyperparamètres, métriques) ; interface graphique simple (Streamlit ou Gradio) permettant de saisir un profil via un formulaire.

## Analyse éthique et réglementaire

---

Cette dernière partie évalue votre capacité de raisonnement. Appuyez vos réponses sur des observations concrètes issues de vos données et de vos résultats.

### Protection des données personnelles (RGPD)

- Qualifiez la nature des données mobilisées : lesquelles sont des données personnelles ? Certaines relèvent-elles de catégories particulières au sens de l'article 9 du RGPD ?
- Quelle base légale pourrait justifier ce traitement de démarchage ? Quelles obligations en découlent (information des personnes, minimisation des données, durée de conservation) ?

### Biais et équité

- Mesurez la performance de votre modèle par sous-groupe (par exemple par tranche d'âge ou par profession) : le taux de sélection, ou le taux de faux positifs / faux négatifs, varie-t-il fortement d'un groupe à l'autre ?
- Un groupe est-il systématiquement moins sollicité ou moins bien servi par le modèle ?

## Dictionnaire des données

Le jeu **bank-additional-full.csv** (<https://archive.ics.uci.edu/dataset/222/bank+marketing>) comporte 20 variables explicatives et 1 variable cible (y). Le séparateur d'origine est le point-virgule (;).

### Données socio-démographiques du client

| Variable  | Description                                                                                                                                                        |
|-----------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| age       | Âge du client (numérique).                                                                                                                                         |
| job       | Type d'emploi (catégoriel : admin., blue-collar, entrepreneur, housemaid, management, retired, self-employed, services, student, technician, unemployed, unknown). |
| marital   | Statut marital (catégoriel : married, single, divorced, unknown ; « divorced » inclut les personnes veuves).                                                       |
| education | Niveau d'éducation (catégoriel : basic.4y, basic.6y, basic.9y, high.school, illiterate, professional.course, university.degree, unknown).                          |

### Situation bancaire

| Variable | Description                                                              |
|----------|--------------------------------------------------------------------------|
| default  | Le client a-t-il un crédit en défaut de paiement ? (yes / no / unknown). |
| housing  | Le client a-t-il un prêt immobilier ? (yes / no / unknown).              |
| loan     | Le client a-t-il un prêt personnel ? (yes / no / unknown).               |

### Dernier contact de la campagne en cours

| Variable    | Description                                                                                                                                 |
|-------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| contact     | Type de moyen de contact (catégoriel : cellular, telephone).                                                                                |
| month       | Mois du dernier contact de l'année (jan, feb, ..., dec).                                                                                    |
| day_of_week | Jour de la semaine du dernier contact (mon, tue, wed, thu, fri).                                                                            |
| duration    | <i>Durée du dernier contact, en secondes (numérique). À manier avec précaution : cette valeur n'est connue qu'une fois l'appel terminé.</i> |

### Historique de campagne

| Variable | Description                                                                                                                          |
|----------|--------------------------------------------------------------------------------------------------------------------------------------|
| campaign | Nombre de contacts effectués durant cette campagne pour ce client (numérique, inclut le dernier contact).                            |
| pdays    | <i>Nombre de jours écoulés depuis le dernier contact d'une campagne précédente (numérique ; 999 signifie « jamais recontacté »).</i> |
| previous | Nombre de contacts effectués avant cette campagne pour ce client (numérique).                                                        |
| poutcome | Résultat de la campagne marketing précédente (catégoriel : failure, nonexistent, success).                                           |

### Contexte socio-économique

| Variable       | Description                                                             |
|----------------|-------------------------------------------------------------------------|
| emp.var.rate   | Taux de variation de l'emploi — indicateur trimestriel (numérique).     |
| cons.price.idx | Indice des prix à la consommation — indicateur mensuel (numérique).     |
| cons.conf.idx  | Indice de confiance des consommateurs — indicateur mensuel (numérique). |

| Variable    | Description                                                |
|-------------|------------------------------------------------------------|
| euribor3m   | Taux Euribor à 3 mois — indicateur journalier (numérique). |
| nr.employed | Nombre de salariés — indicateur trimestriel (numérique).   |

#### Variable cible

| Variable | Description                                                                      |
|----------|----------------------------------------------------------------------------------|
| y        | <i>Le client a-t-il souscrit un dépôt à terme ? (yes / no) — variable cible.</i> |